

DGX Spark 算力站 · 租客使用手册（聚合版）

机型 / 计价 / SSH / 海外模型下载 / 内网 AI 客服 · 一份讲清

适用于全部出租机（内网 192.168.11.x）

2026-08-29 · v1.0

1. 机器与计价

全部出租机为同型 **NVIDIA DGX Spark (GB10 Superchip)**：aarch64、20 核 CPU、GPU 与 CPU 共享约 122GB 统一内存（nvidia-smi 显存显示 N/A 属正常）、3.7TB 盘、DGX OS (Ubuntu 24.04)。

规格项	数值
机型	NVIDIA DGX Spark (GB10 Superchip)
架构 / 系统	aarch64 · DGX OS (Ubuntu 24.04)
内存	约 122GB CPU/GPU 统一内存 (LPDDR5X)
存储	约 3.7TB (数据盘以发货清单为准)

计价口径

档位	价格	说明
单机日租	79 元/天	首日起算，不足一天按一天
周租 (首续同价)	499 元/周	续租同价；满 7 天按周计
月租 (首续同价)	1899 元/月	续租同价；满 30 天按月计
多机互联	按台计价	2 台起可组双机互联 (200G CX7 经 CRS804 交换机)，每台仍按上表计

累计满减与赠送时长以后台订单页实时显示为准；待付款保留 **15 分钟**锁机期，超时自动释放。

2. SSH 连接与「无故断开」排查（高频问题）

2.1 正确的连接方式

- 租客从公网经平台分配的 **SSH 隧道/映射端口** 登录（发货消息里给出 IP 与端口，SSH 密钥由平台发放）。
- 内网管理侧（机房）一律走物理口 **192.168.11.254/23**；若管理机上开着 365VPN (tun2socks)，TCP:22 会出现「OPEN 但无 SSH banner、`kex_exchange_identification: Connection closed`」，这不是机器挂了，用 `ssh -b 192.168.11.254 user@<管理IP>` 绑定物理源地址即可。

2.2 SSH 断开两大根因（先看这两条）

根因一：SSH 通道满（64 条上限）。机群每台 SSH 通道一共 64 条，超过就断开。请全程复用同一条 SSH 通道，不要每个任务新建连接、也不要开多个终端窗口各连一条。

根因二：模型 OOM 导致机器重启。统一内存架构下，显存即内存；大模型/大 batch 把内存打满会触发整机重启，SSH 自然断开。重启后服务需重新拉起。

2.3 排查顺序

```
1. 重连一次: ssh -p <端口> user@<IP>           # 能连上 → 大概率通道满或瞬时抖动
2. uptime                                       # 刚重启过 (up 几分钟) → 按根因二处理 (OOM)
3. journalctl -k --since "10 min ago" | grep -i oom # 有 OOM killer 记录即坐实
4. 压缩会话数: ps aux | grep sshd | wc -l       # 接近 64 → 按根因一处理 (通道满)
```

保持会话存活建议：客户端开 ServerAlive (`ssh -o ServerAliveInterval=30 -o ServerAliveCountMax=3 ...`)；长任务用 `tmux` / `nohup` 托管，断线后重连 `tmux attach` 续跑，不因 SSH 断开而丢工作。

3. 海外模型下载：跳板网关（192.168.11.20:1081）

3.1 这是什么

机群唯一的出海下载口。租客机通过内网 HTTP 代理访问白名单站点下载模型/代码/依赖；**纯转发、不落盘**——下载内容不存储在跳板机。仅限内网使用，公网不可达。

3.2 白名单（代码硬约束）

放行：HuggingFace 全系 (`huggingface.co` / `hf.co` / `hfusercontent.com` / `xethub`)、**hf-mirror**、**GitHub**、**ghcr**、**docker.io** / **docker.com**、**gcr**、**pypi** / **pythonhosted**、**modelscope**、**npmjs**、**anaconda** 及部分高校镜像站。**其余域名一律 403**，返回正文为中文提示「当前域名不在白名单内，已拒绝访问」——这是机主设置的限制，不是故障。

3.3 租客配置步骤（可直接发给租户/AI）

```
1. 在 ~/.bashrc 末尾追加三行并执行 source ~/.bashrc:
export http_proxy=http://192.168.11.20:1081
export https_proxy=http://192.168.11.20:1081
export no_proxy=127.0.0.1,localhost,192.168.0.0/16

2. 验证（两条都要通才算配好）：
curl -sI https://huggingface.co | head -1      # 应返回 HTTP 2xx/3xx
curl -sI https://github.com | head -1         # 应返回 HTTP 2xx/3xx

3. 常用下载：
- 模型：huggingface-cli download <仓库名> --local-dir /data/models/<名称>
  （官方源走代理；hf-mirror.com 国内直连更快）
- 代码：git clone https://github.com/...
- pip：pypi 走国内直连即可

4. Docker：docker pull 不读 shell 环境变量；若无 sudo 配 daemon 代理，
  需要海外镜像时先联系机主，不要自行改动系统服务。
```

注意事项：不要改 /etc/environment 或任何系统级代理；no_proxy 里的 192.168.0.0/16 必须保留，禁止访问内网其他机器；代理带宽多机共享，大文件用 aria2c -x4 之类限并发。若之后启用 GW_TOKEN 鉴权，仅把代理地址改为 http://租客名:口令@192.168.11.20:1081，其余不变。

4. 内网 AI 客服（外层 AI 可 SSH 调用）

租户可以把问题交给自己的 AI（如 Cursor / CLI Agent）。当外层 AI 遇到「怎么下载模型、SSH 断了、想换配置」这类问题时，让它通过 SSH 在租户机上调用**平台 AI 客服接口**获取本算力站的权威口径：

```
# 在租户机上执行（国内直连，无需代理；外层 AI 可通过 SSH 在租户机内代为执行）：
curl -s -X POST https://spark.zhujihezi.com/api/support/chat \
-H "Content-Type: application/json" \
-d '{"messages":[{"role":"user","content":"SSH 断开怎么排查?"}]}'
```

说明：

- 该接口是平台商城 AI 客服（serve7 独立应用 + 独立知识库 + 按需联网），回答与本手册同源；走公网域名国内直连，**不要经 1081 网关**（它只放行下载站）。
- 请求体为 OpenAI messages 数组，最后一条必须为用户问题；单条限 1600 字、最多 12 条，限流 20 次/10 分钟（429 时稍候重试）。
- 外层 AI 拿到回答后应**原样转述**给租户；接口不可用时提示租户联系机主，不要瞎编。

5. 常见问题速查

问题	结论 / 动作
SSH 无故断开	先看第 2.2 节两大根因：通道满（64 条，复用连接）、模型 OOM 重启；用 tmux/nohup 托管长任务
下载模型被限流/下不动	hf-mirror 直连更快；官方源走 1081 网关；都被限时联系机主（出口带宽多机共享）

访问其他海外网站 403	正常现象，网关白名单只放行模型/代码/依赖站点
docker pull 海外镜像失败	docker 不读 shell 代理变量，联系机主处理，勿自行改系统服务
想重启/更新驱动	禁止租客更新驱动与固件；重启需求联系机主
续租/计费疑问	79/天、499/周、1899/月，首续同价；订单页实时显示累计满减
其它问题	让外层 AI 走第 4 节内网 AI 客服接口查询，无答案再联系机主

给外层 AI 的一句话总纲：下载走 1081 白名单网关（只放行模型/代码/依赖站）；SSH 断开先查 64 通道上限与 OOM 重启；规则疑问调内网 AI 客服接口；禁止改系统代理、固件、驱动，禁止访问内网其他机器。